Predicción multiclase de riesgo cardiovascular en población adulta

Enzo Castro, Rodrigo Martínez Jiménez y Pablo Sánchez Mérida

Resumen

Palabras clave

I. Introducción

I-A. Contexto clínico y motivación

LAS enfermedades cardiovasculares son una de las principales causas de mortalidad en el mundo. Detectar de forma temprana el nivel de riesgo de cada paciente permite adaptar las intervenciones preventivas y aprovechar mejor los recursos sanitarios. Con este fin, el Hospital Morales Meseguer ha facilitado los datos de sus pacientes para desarrollar herramientas predictivas que ayuden a evaluar el riesgo cardiovascular [1].

I-B. Objetivos

El objetivo es clasificar a los pacientes (adultos) en tres niveles de riesgo cardiovascular (bajo, moderado y alto) a partir de variables sociodemográficas, clínicas, analíticas y de estilo de vida. Para ello se analiza la calidad del dataset, se proponen técnicas de preprocesamiento para sus problemáticas y se comparan varios modelos base y de ensamble con un mismo esquema de validación, con especial atención a la detección de los pacientes de riesgo alto.

II. Materiales

II-A. Descripción del dataset

El conjunto de datos incluye 2.254 pacientes y 28 variables [1]: 27 de entrada y la variable objetivo, el nivel de riesgo cardiovascular (0: bajo, 1: moderado y 2: alto). De las variables de entrada, 19 son numéricas: la edad, la presión arterial, el perfil lipídico, la glucosa y la hemoglobina glicosilada, el índice de masa corporal y el perímetro de cintura, marcadores analíticos como la proteína C reactiva, el ácido úrico o el aclaramiento de creatinina, y hábitos como el consumo de alcohol, los años de tabaquismo, el sueño o el ejercicio. Otras 5 son binarias (tabaquismo activo, hipertensión previa, diabetes, tratamiento con estatinas y uso de antihipertensivos) y 3 son categóricas: el tipo de alimentación, el nivel de actividad física y los antecedentes familiares.

II-B. Análisis exploratorio

II-B1. Variable objetivo y desbalance de clases

La clase de riesgo bajo agrupa a 1.127 pacientes (50 %), la de riesgo moderado a 676 (30 %) y la de riesgo alto a 451 (20 %). El desbalance no es muy grande, pero un modelo que diga siempre riesgo bajo, acertaría la mitad de los casos sin haber aprendido nada, por lo que la exactitud (*accuracy*) no sirve en este caso para evaluar los modelos [2]. Además, la clase minoritaria es la más importante clínicamente: clasificar a un paciente de riesgo alto como de riesgo bajo lo dejaría sin seguimiento. Por ello, todas las particiones se hacen de forma estratificada.

Práctica 1 de Machine Learning. Máster Universitario en Inteligencia Artificial, Universidad de Murcia, curso 2026/2027.

II-B2. Distribución de las variables

Las medianas de las variables numéricas cambian de forma ordenada entre las clases, aunque sus distribuciones se solapan mucho y las clases no son linealmente separables. Las variables binarias se asocian al riesgo, de la manera esperada: el 56 % de los pacientes de riesgo alto tiene hipertensión previa y el 53 % toma antihipertensivos. En las categóricas, tiene riesgo alto el 12 % de los pacientes con dieta mediterránea o vegetariana, frente al 29 % de los que siguen la occidental; el riesgo alto baja de forma ordenada con la actividad física, del 31 % en los sedentarios al 8 % en los muy activos; y con los antecedentes familiares pasa del 12 % (ninguno) al 22 % (materno), 28 % (paterno) y 40 % (ambos).

II-B3. Valores faltantes

Cuatro variables tienen valores nulos: el colesterol LDL (6,0 %), la glucosa en ayunas (5,0 %), las horas de sueño (8,0 %) y la proteína C reactiva (7,0 %). Los nulos se reparten entre pacientes distintos, de modo que el 23,6 % de los pacientes tiene al menos uno y eliminarlos supondría perder casi uno de cada cuatro. En cada variable, el porcentaje de nulos apenas cambia entre las tres clases de riesgo (como mucho 2,5 puntos), y al ejecutar un test chi-cuadrado, se confirma que el hecho de que falte un dato no está relacionado con el riesgo del paciente. Por eso no hace falta añadir indicadores de nulo.

II-B4. Calidad de los datos

La revisión de rangos y de la coherencia entre variables muestra tres tipos de errores de registro, recogidos en la Tabla I. El primero son valores imposibles, como consumos de alcohol negativos, un índice de masa corporal (IMC) de 3,6 o edades de 9,8 y 14,4 años en pacientes que llevan más de 12 años fumando. El segundo son incoherencias entre variables: en 44 pacientes la presión sistólica es menor o igual que la diastólica, y en 559 (el 25 %) la suma de HDL y LDL supera al colesterol total. El tercero son valores repetidos, de forma sospechosa: en la presión sistólica, el colesterol total, los triglicéridos y el ácido úrico aparecen dos valores con decimales que se repiten entre 36 y 74 veces (por ejemplo, 452,7 mg/dL en los triglicéridos), cuando el siguiente valor más frecuente se repite como mucho 16 veces. Estos valores están por encima del máximo del resto de pacientes, afectan al 4–6 % de ellos y esos pacientes no tienen más riesgo que el resto, por lo que se interpretan como nulos camuflados: 449 valores en total.

II-B5. Correlaciones y redundancia

Se usa la correlación de Spearman en lugar de la de Pearson, porque varias variables tienen distribuciones asimétricas y el riesgo es una variable con orden (bajo, moderado y alto), no una medida continua. Spearman trabaja con el orden de los valores, así que no le afectan ninguna de las dos. Ningún par de variables de entrada supera en valor absoluto 0,11, así que no hay variables redundantes que eliminar. Además, pares que clínicamente deberían estar relacionados, parecen prácticamente independientes (presión sistólica y diastólica, 0,01; glucosa y hemoglobina glicosilada, 0,05), lo que, junto con la incoherencia entre HDL, LDL y colesterol total, sugiere que las variables se generaron de forma independiente. Respecto al riesgo, las relaciones más importantes son el consumo de alcohol (0,39), la hemoglobina glicosilada (0,28), la proteína C reactiva (0,28) y el uso de antihipertensivos (0,24), y las negativas más marcadas, la frecuencia de ejercicio ($-0{,}21$) y el colesterol HDL ($-0{,}20$). Todas son débiles o moderadas, puesto que el riesgo depende de la combinación de muchas variables y no de una sola.

II-C. Problemáticas detectadas

El análisis exploratorio identifica los siguientes problemas, los cuales se tratan en el preprocesamiento de la Sección III:

- Valores faltantes en 4 variables, que pasan a 12 tras corregir los errores de registro.
- Errores de registro: valores imposibles, incoherencias entre variables y nulos camuflados.
- Desbalance de clases, con la clase de riesgo alto como minoritaria.
- Variables categóricas en texto, que los modelos no pueden usar directamente.
- Escalas muy distintas entre variables y presencia de valores extremos.

III. MÉTODOS

III-A. Preprocesamiento

III-A1. Limpieza de errores de registro

Los errores de registro se corrigen mediante reglas fijas, definidas a partir de los valores clínicamente posibles de cada variable (Tabla I). Dado que estas reglas no se estiman a partir de los datos, pueden aplicarse antes de dividir el conjunto en entrenamiento y test sin riesgo de fuga de datos. El criterio principal es pasar a nulo los valores imposibles, que después se

Tabla I
ERRORES DE REGISTRO DETECTADOS Y REGLA APLICADA

Problema	Casos	Regla
HDL o triglicéridos negativos	4 + 4	Pasar a nulo
Consumo de alcohol negativo	177	Recortar a 0
IMC menor de 10	8	Pasar a nulo
Edad menor de 18 años	4	Pasar la edad a nulo
Más de 7 días de ejercicio a la semana	41	Recortar a 7
Presión sistólica $\leq$ diastólica	44	Pasar las dos a nulo
Valores repetidos (nulos camuflados)	449	Pasar a nulo
HDL + LDL $>$ colesterol total	559	No se corrige (limitación)

imputan, salvo cuando el propio error conserva información sobre el riesgo. Es el caso del consumo de alcohol en negativo: esos 177 pacientes solo tienen un 2 % de riesgo alto, de modo que el valor indica un consumo bajo y se recorta a 0 en lugar de imputarle la mediana (4,3 unidades de bebida a la semana). De la misma manera, los 41 pacientes con más de 7 días de ejercicio a la semana, con un 5 % de riesgo alto, se recortan a 7. Los cuatro menores de 18 años no se eliminan: al llevar años fumando, son adultos con la edad mal registrada, así que solo su edad se pasa a nulo y se conservan el resto de datos. En cuanto al IMC solo se anula lo que es totalmente imposible (menos de 10); entre 10 y 12, estaría dentro de una desnutrición extrema, pero posible. La incoherencia entre HDL, LDL y colesterol total no se corrige, porque no se puede saber qué variable es la errónea y además, afecta a un cuartode los pacientes, por lo que se documenta como limitación del dataset.

III-A2. Codificación de variables categóricas

Las tres variables categóricas se transforman en números con una correspondencia fija entre cada categoría y su valor. El nivel de actividad tiene un orden natural, de sedentario a muy activo, y cuanto más activo es el paciente, menor es el porcentaje de riesgo alto: del 31 % en los sedentarios baja al 8 % en los muy activos. Por eso se codifica como variable ordinal de 0 a 3, conservando ese orden. El tipo de alimentación no tiene orden y se codifica con *one-hot*. Con las cuatro columnas, una siempre se puede deducir de las otras tres, lo que se conoce como colinealidad perfecta y perjudica a modelos como la regresión logística. Por eso se elimina la columna de la dieta mediterránea, la de menor riesgo alto (12 %), que queda como categoría de referencia: un paciente con las otras tres columnas a 0 sigue la dieta mediterránea. Los antecedentes familiares se representan con dos variables binarias, una para la madre y otra para el padre, de modo que un paciente con antecedentes por ambas partes tiene las dos a 1. Esta codificación refleja bien cómo influyen en el riesgo: el riesgo alto pasa del 12 % sin antecedentes al 22 % con antecedentes maternos y al 28 % con paternos, y llega al 40 % con ambos, casi la suma de los dos efectos por separado.

III-A3. Imputación de valores faltantes

Tras la limpieza, 12 variables tienen nulos y el 39 % de los pacientes tiene al menos uno, así que eliminar filas supondría perder 884 pacientes. Siguiendo el tratamiento de valores faltantes de la asignatura [3], para elegir el método de imputación se realizó un experimento: sobre los 1.370 pacientes sin nulos se ocultaron al azar valores en la misma proporción que los nulos reales, se reconstruyeron con la media, la mediana, KNN (5 y 25 vecinos) e `IterativeImputer`, y se midió el error absoluto medio en 30 repeticiones. La mediana iguala o mejora a todas las alternativas: KNN con 5 vecinos tiene el mayor error en las 12 variables, y la mayor ventaja de `IterativeImputer` (0,2 mg/dL en la glucosa) queda muy por debajo de la variación entre repeticiones. Tiene sentido, porque las variables con nulos apenas se relacionan con el resto (la correlación más alta es de 0,12): KNN e `IterativeImputer` estiman el valor que falta a partir de las demás variables del paciente, y si estas no aportan información sobre él, no pueden hacerlo mejor que la mediana. Por el mismo motivo se descartó calcular el LDL con la fórmula de Friedewald, cuyo error (47,4 mg/dL) supera al de la mediana (29,5 mg/dL). La imputación con la mediana se realiza dentro del *pipeline*, de modo que la mediana se calcula solo con los datos de entrenamiento de cada fold.

III-A4. Escalado

Las variables numéricas se escalan con `RobustScaler`, que usa la mediana y el rango intercuartílico y es menos sensible a los valores extremos que la estandarización. Se aplica en todos los modelos: a los basados en árboles no les afecta, porque el escalado no cambia el orden de los valores, pero SMOTENC busca vecinos por distancia y, sin escalar, la dominarían el colesterol y los triglicéridos. Las variables binarias y categóricas no se escalan.

III-A5. Tratamiento del desbalance

Se comparan varias opciones en cada modelo: no balancear; `class_weight` con la opción `balanced`, que aplica el aprendizaje sensible al coste [2] y pondera el error de cada clase de forma inversa a su frecuencia (pesos de 0,67, 1,11 y 1,66 para riesgo bajo, moderado y alto); SMOTENC [2], [4], que genera pacientes sintéticos de las clases minoritarias hasta

igualarlas (901 por clase en el entrenamiento); y Tomek [4], que elimina pacientes de las clases mayoritarias situados en la frontera con otra clase. Se utiliza SMOTENC y no SMOTE porque SMOTE interpola también las variables binarias y categóricas: con el mismo preprocesado, 2.967 de los 9.900 valores categóricos de sus pacientes sintéticos tenían decimales (por ejemplo, un fumador con valor 0,67), frente a ninguno con SMOTENC, que asigna la categoría más frecuente entre los vecinos. Las técnicas de remuestreo se aplican dentro del *pipeline* de `imbalanced-learn`, solo sobre los datos de entrenamiento de cada fold, de modo que la validación se hace siempre con pacientes reales.

III-A6. Técnicas descartadas

Además de las ya mencionadas (Friedewald, KNN e `IterativeImputer` para imputar, y SMOTE para balancear), se descartaron también:

- Eliminar los pacientes con nulos, porque se perdería el 39 % de la muestra.
- Pasar a nulo los valores fuera de unos rangos clínicos de referencia. Una vez quitados los nulos camuflados, solo 134 valores se salen de ellos y no parecen errores: en el HDL, la proteína C reactiva y la hemoglobina glicosilada, entre el 29 y el 30 % de esos pacientes es de riesgo alto, frente al 20 % del total.
- Eliminar variables por correlación, porque ningún par supera el valor de 0,11.

III-B. Esquema de validación

Los datos se dividen una sola vez en entrenamiento (80 %, 1.803 pacientes) y test (20 %, 451 pacientes), de forma estratificada para mantener la proporción de clases en ambos conjuntos. El test se reserva para una única evaluación final. Los modelos se ajustan y comparan con validación cruzada estratificada de 5 folds [3], [5] (`StratifiedKFold` con mezcla aleatoria), con la misma semilla (42) y los mismos folds para todos, lo que permite comparar los modelos fold a fold. Todo lo que se aprende de los datos forma parte de un *pipeline* común, construido con scikit-learn e `imbalanced-learn`: imputación y escalado de las variables numéricas, balanceo y modelo. Se ajusta solo con los folds de entrenamiento, lo que evita la fuga de información a validación. La partición, los folds de validación, las métricas y el *pipeline* se definen en un único módulo utilizado por todo el grupo.

III-C. Métricas de evaluación

Se utilizan F1, precisión y recall, en su versión macro, que da el mismo peso a las tres clases y evita que domine la mayoritaria [2], [3]. La métrica más crítica es el recall de la clase de riesgo alto: un falso negativo deja a un paciente de riesgo alto sin seguimiento ni tratamiento preventivo, mientras que un falso positivo supone pruebas o tratamientos innecesarios, provocando un coste menor. Aun así, el recall no se usa para elegir hiperparámetros, porque un modelo que clasificara a todos los pacientes como de riesgo alto tendría un recall de 1 y sería inútil (su F1 macro sería de 0,11). Por eso los modelos se ajustan con el F1 macro, que equilibra precisión y recall en las tres clases. El recall de riesgo alto se utiliza después de dos formas: para elegir entre modelos con un F1 macro parecido y para analizar sus errores desde el punto de vista clínico. En ese análisis, se utiliza también la precisión de esa clase, que indica cuántas de las alarmas del modelo son correctas y la matriz de confusión, que muestra si un paciente de riesgo alto se clasifica como riesgo moderado o como bajo.

III-D. Modelos

III-D1. Modelos base

Árbol de decisión. Clasifica a los pacientes mediante una secuencia de preguntas sobre sus variables, por ejemplo si la proteína C reactiva supera un cierto umbral. En cada paso elige la variable y el umbral que mejor separan las clases, es decir, los que dejan grupos de pacientes lo más homogéneos posible. Sus decisiones se pueden leer directamente, pero si crece sin límite acaba memorizando los datos de entrenamiento. Se ajustan la medida de homogeneidad (Gini o entropía), la profundidad máxima (3, 5, 8, 12 o sin límite) y el número mínimo de pacientes por hoja (1, 5 o 20), que controlan cuánto puede crecer.

k vecinos más cercanos (kNN). Asigna a cada paciente la clase más frecuente entre los k pacientes del entrenamiento más parecidos a él. Como el parecido se mide con distancias, necesita que las variables estén escaladas, si no, las de valores más grandes dominarían el cálculo. Se ajustan el número de vecinos (de 3 a 75) y la forma de medir la distancia (euclídea o Manhattan). No admite `class_weight`, porque no aprende parámetros a los que se pueda dar peso: solo compara cada paciente con los del entrenamiento.

Tabla II
F1 MACRO Y, ENTRE PARÉNTESIS, RECALL DE RIESGO ALTO EN VALIDACIÓN SEGÚN LA TÉCNICA DE BALANCEO. EN NEGRITA, LA TÉCNICA ELEGIDA EN CADA MODELO

Modelo	Sin balancear	`class_weight`	SMOTENC	Tomek
Árbol de decisión	0,545 (0,50)	0,532 (0,60)	**0,541 (0,60)**	0,540 (0,52)
kNN	0,537 (0,41)	–	**0,590 (0,77)**	0,549 (0,49)
Random Forest	0,611 (0,56)	**0,648 (0,72)**	0,627 (0,69)	0,609 (0,68)

III-D2. Modelos de ensamble

Random Forest. Es un ensamble de tipo *bagging* [2], [6]: combina numerosos árboles de decisión y clasifica a cada paciente mediante votación entre ellos. Para que los árboles sean distintos entre sí, cada uno se entrena con una muestra aleatoria de los pacientes, tomada con reemplazo (*bootstrap*), y en cada división solo puede elegir entre un subconjunto aleatorio de variables. Así, aunque cada árbol por separado sobreajuste, sus errores se compensan al promediarlos y el conjunto generaliza mejor que un único árbol. Se ajustan el número de árboles (100 o 300), la profundidad máxima (5, 10 o sin límite), el número de variables que se prueban en cada división (la raíz cuadrada del total o la mitad) y el número mínimo de pacientes por hoja (1, 5 o 10).

III-E. Ajuste de hiperparámetros

Todos los modelos se ajustan con búsqueda en rejilla (`GridSearchCV`) [5] sobre la validación cruzada. En cada combinación se calculan todas las métricas, en entrenamiento y en validación, y se elige la de mayor F1 macro. Con el mismo criterio se elige la técnica de balanceo de cada modelo: el F1 macro y, si la diferencia queda dentro de la desviación entre folds, se escoge por el recall de riesgo alto.

III-F. Comparación estadística de modelos

III-G. Entorno y reproducibilidad

El código está en el repositorio de GitHub (`github.com/enzocastrozn/machine_learning`), con Python 3.12 y las versiones de las dependencias fijadas con uv y en `requirements.txt`. Se usa una única semilla (42) en la partición, los folds, el remuestreo y los modelos. Los notebooks de cada miembro comparten el módulo de preprocesamiento y validación, y guardan los resultados de validación, incluida la nota de cada fold, para la comparación final.

IV. ANÁLISIS DE RESULTADOS

IV-A. Comparación de técnicas de preprocesamiento

La Tabla II muestra el F1 macro y el recall de riesgo alto en validación de cada modelo con cada técnica de balanceo. En el árbol de decisión las cuatro opciones empatan en F1 macro (entre 0,532 y 0,545, dentro de la desviación entre folds), pero balancear con `class_weight` o con SMOTENC eleva el recall de riesgo alto de 0,50 a 0,60; se elige SMOTENC por su mayor precisión en esa clase. En kNN, SMOTENC mejora ambas métricas (F1 de 0,537 a 0,590 y recall de 0,41 a 0,77). En Random Forest, `class_weight` obtiene el mejor F1 macro (0,648) y el mejor recall de riesgo alto (0,72). Tomek no es la mejor opción en ningún modelo: solo elimina 182 pacientes de la frontera (82 de riesgo bajo y 100 moderados) y ninguno de riesgo alto, así que el desbalance se mantiene (819, 441 y 361 pacientes). Se concluye que no hay una técnica de balanceo mejor para todos los modelos, lo que justifica haberlas comparado en cada uno en lugar de fijar una sola técnica para todos.

IV-B. Resultados en validación cruzada

La Tabla III resume la mejor configuración de cada modelo. Entre el árbol de decisión, kNN y Random Forest, el mejor F1 macro corresponde a Random Forest, que supera a kNN en los cinco folds (por 0,058, 0,065, 0,057, 0,088 y 0,025). kNN, en cambio, obtiene el mayor recall de riesgo alto y solo clasifica como riesgo bajo a 8 de los 361 pacientes de riesgo alto del entrenamiento, a costa de más falsas alarmas: su precisión de riesgo alto es de 0,56, frente a 0,65 en Random Forest.

Tabla III
MEJOR CONFIGURACIÓN DE CADA MODELO EN VALIDACIÓN CRUZADA (MEDIA ± DESVIACIÓN ENTRE FOLDS)

Modelo	Balanceo	F1 macro	Recall alto	Precisión alto	Alto → bajo
Árbol de decisión	SMOTENC	0,541 ± 0,033	0,60	0,50	37
kNN	SMOTENC	0,590 ± 0,020	0,77	0,56	8
Random Forest	`class_weight`	0,648 ± 0,035	0,72	0,65	10

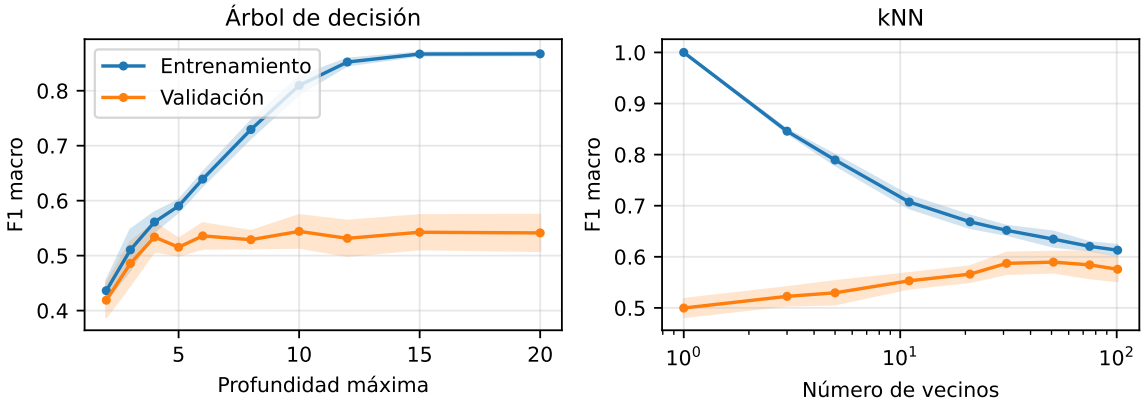


Figura 1. Curvas de validación del árbol de decisión (profundidad máxima) y de kNN (número de vecinos): F1 macro en entrenamiento y validación, con la media y la desviación entre folds.

IV-C. Análisis del sobreajuste

La Fig. 1 muestra las curvas de validación del árbol de decisión y de kNN. En el árbol, a partir de profundidad 4, la validación oscila entre 0,51 y 0,54 mientras el entrenamiento sube hasta 0,87: por lo que la profundidad adicional solo sirve para memorizar pacientes. La mejor combinación (entropía, sin límite de profundidad y 5 pacientes por hoja; 0,867 en entrenamiento frente a 0,541 en validación) empata con otra mucho más sencilla (Gini, profundidad 12 y 20 pacientes por hoja), que obtiene 0,540 ± 0,008 con solo 0,693 en entrenamiento y sería preferible por su menor sobreajuste. En kNN se aprecia el compromiso entre sesgo y varianza: con un vecino el entrenamiento es perfecto y la validación se queda en 0,50; al aumentar el número de vecinos, la validación sube hasta estabilizarse entre 31 y 51, y el valor elegido (51) apenas sobreajusta (0,635 frente a 0,590). Random Forest alcanza 0,997 en entrenamiento, pero es el que mejor generaliza, con 0,107 más en validación que el árbol individual: cada árbol sobreajusta por separado, pero al promediar muchos árboles distintos se reduce la varianza, además, limitar a 10 los pacientes por hoja reduce su F1 de entrenamiento a 0,90 sin empeorar la validación.

IV-D. Matrices de confusión y errores clínicamente graves

IV-E. Importancia de las variables

La importancia por permutación [2], [6] de Random Forest se calcula en los folds de validación, porque en entrenamiento el modelo memoriza a los pacientes y las variables se compensan entre sí. Las más relevantes son la proteína C reactiva y el consumo de alcohol, seguidas a distancia por el ácido úrico y la hemoglobina glicosilada (Fig. 2), concordando con las correlaciones del análisis exploratorio. Otras variables relacionadas con el riesgo en ese análisis, como el HDL o la frecuencia de ejercicio, tienen una importancia dentro del ruido entre folds: no significa que no estén relacionadas con el riesgo, sino que el modelo apenas pierde F1 al desordenarlas, probablemente porque su efecto es pequeño frente al de las dos primeras. El árbol de decisión confirma esta jerarquía y permite leer sus umbrales en unidades clínicas deshaciendo el escalado: su primer corte separa a los pacientes con una proteína C reactiva de 0,97 mg/L, muy próximo al umbral de 1 mg/L que la AHA y los CDC emplean para el riesgo cardiovascular bajo.

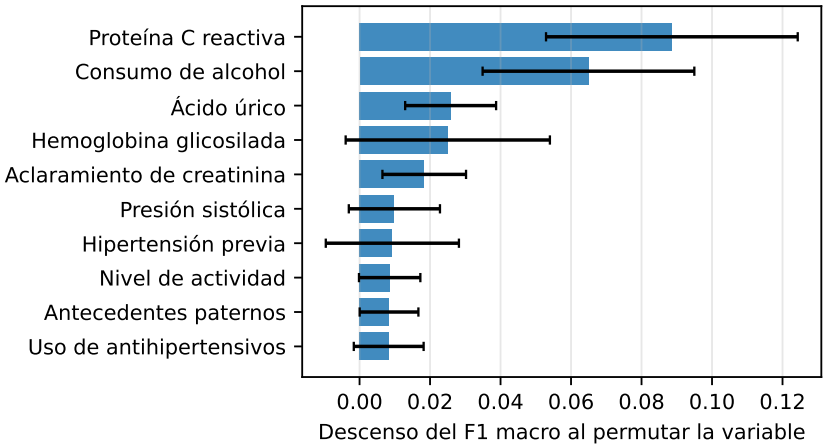


Figura 2. Importancia por permutación de las 10 variables más relevantes para Random Forest: descenso medio del F1 macro en los folds de validación y su desviación.

IV-F. Test estadísticos

IV-G. Evaluación final en test

V. Discusión y conclusiones

V-A. Mejor modelo y justificación

V-B. Complejidad, interpretabilidad y robustez

V-C. Limitaciones del dataset

V-D. Posibles mejoras y trabajo futuro

Referencias

[1] "Práctica 1. Machine Learning: Predicción multiclase de riesgo cardiovascular en población adulta," Enunciado de la práctica, Máster Universitario en Inteligencia Artificial, Universidad de Murcia, 2026, curso 2026/2027.
[2] R. Martínez España y J. T. Palma, "Tema 2. Técnicas supervisadas," Apuntes de Machine Learning, Máster Universitario en Inteligencia Artificial, Universidad de Murcia, 2026, curso 2026/2027.
[3] ——, "Tema 1. Introducción al machine learning," Apuntes de Machine Learning, Máster Universitario en Inteligencia Artificial, Universidad de Murcia, 2026, curso 2026/2027.
[4] "Notebook 3: Desbalanceo," Material de prácticas de Machine Learning, Máster Universitario en Inteligencia Artificial, Universidad de Murcia, 2026, curso 2026/2027.
[5] "Notebook 2: Técnicas, métricas y validación," Material de prácticas de Machine Learning, Máster Universitario en Inteligencia Artificial, Universidad de Murcia, 2026, curso 2026/2027.
[6] "Notebook 4: Ensambles," Material de prácticas de Machine Learning, Máster Universitario en Inteligencia Artificial, Universidad de Murcia, 2026, curso 2026/2027.